

ANEXO 1 — Repositorio de código y pipeline ENEMDU

Contrato CO-01184-2026 · Septiembre 2026

Elaborado por: Econ. Michelle Luzuriaga — Técnico Especializado, Dirección de Proyectos Estratégicos

1. Árbol de directorios (profundidad 3)

```
ucuenca-sabe/
├── .github/
│   └── workflows/
│       └── noticias_economia.yml
├── Claude outputs/
│   ├── CHECKLIST_INSTALACION.md
│   ├── DASHBOARD_ARCHITECTURE.md
│   ├── INSTALACION_DASHBOARD.md
│   ├── MVP_dashboard_empleabilidad_UPDATED.html
│   ├── README_VISUALIZACION.md
│   └── RESUMEN_INSTALACION.txt
├── config/
│   └── config.yaml
├── data/
│   ├── bronze/
│   │   ├── externas/
│   │   ├── internas/
│   │   └── investigacion/
│   ├── gold/
│   │   └── enemdu/
│   └── silver/
│       ├── enemdu/
│       ├── noticias_economia/
│       ├── articulos_silver.parquet
│       ├── catastro_docentes.parquet
│       ├── investigadores.csv
│       ├── investigadores.parquet
│       ├── investigadores_completo.parquet
│       ├── publicaciones_silver.parquet
│       ├── silver_catastropure.xlsx
│       └── tesis_silver.parquet
├── docs/
│   ├── README.md
│   └── README_ENEMDU_PIPELINE.md
├── Docs_adicionales/
│   └── Encuestas/
│       └── borrador_encuesta_serivicios_ucuenca_ep.docx
├── empleabilidad_mvp.Report/
│   ├── .pbi/
│   │   └── localSettings.json
│   ├── definition/
│   │   ├── pages/
│   │   ├── report.json
│   │   └── version.json
│   ├── StaticResources/
│   │   └── RegisteredResources/
│   ├── .platform
│   └── definition.pbir
├── empleabilidad_mvp.SemanticModel/
│   ├── .pbi/
│   │   ├── cache.abf
│   │   ├── editorSettings.json
│   │   └── localSettings.json
│   ├── definition/
│   │   ├── cultures/
│   │   ├── tables/
│   │   └── database.tmdl
```

```
├── model.tmdl
├── .platform
├── definition.pbism
├── notebooks/
│   ├── 01_docentes/
│   │   ├── 01_ingesta_gth_pure.ipynb
│   │   └── 02_fuzzy_matching_dspace.ipynb
│   ├── 02_alumni/
│   │   ├── 01_download_kaggle_enemdu.ipynb
│   │   └── 02_review_sav_labels.ipynb
├── powerbi_ucuenca/
│   ├── catastro_pure.Report/
│   │   ├── .pbi/
│   │   ├── definition/
│   │   ├── StaticResources/
│   │   ├── .platform
│   │   └── definition.pbir
│   ├── catastro_pure.SemanticModel/
│   │   ├── .pbi/
│   │   ├── definition/
│   │   ├── .platform
│   │   ├── definition.pbism
│   │   └── diagramLayout.json
│   ├── catastro_pure.pbip
│   └── Tema_UCuenca_2026.json.json
├── reports/
│   ├── powerbi/
│   │   ├── comparativo_nivel_instruccion.csv
│   │   ├── cubo_empleabilidad.csv
│   │   ├── cubo_ocupacion_graduados.csv
│   │   ├── empleabilidad_graduados.csv
│   │   ├── empleabilidad_provincia.csv
│   │   ├── empleabilidad_sexo_edad.csv
│   │   ├── graduados_rama_actividad.csv
│   │   ├── kpi_anual.csv
│   │   └── sobrecalificacion_ocupacion.csv
│   └── schemas/
│       ├── gold_manifest_20260904.json
│       ├── gold_manifest_20260907.json
│       ├── gold_manifest_20260930.json
│       ├── schema_analysis_20260822.json
│       ├── schema_analysis_20260904.json
│       ├── schema_analysis_20260907.json
│       ├── schema_analysis_20260922.json
│       ├── silver_quality_20260904.json
│       └── silver_quality_20260907.json
├── scripts/
│   └── run_enemdu_pipeline.py
├── src/
│   ├── ingestion/
│   │   └── kaggle_downloader.py
│   ├── processing/
│   │   ├── __init__.py
│   │   ├── enemdu_gold_builder.py
│   │   ├── enemdu_mappings.py
│   │   ├── enemdu_schema_analyzer.py
│   │   ├── enemdu_silver_builder.py
│   │   ├── io_utils.py
│   │   └── noticias_sentimiento.py
│   ├── scrapers/
│   │   ├── investigacion_scraper_final.py
│   │   ├── noticias_economia_scraper.py
│   │   └── organizaciones_scraper.py
│   ├── utils/
│   │   └── dspace_parser.py
│   ├── __init__.py
│   └── config.py
```

```

├── visualizacion/
│   ├── scripts/
│   │   ├── generate_dashboard_data.py
│   │   └── generate_noticias_data.py
│   ├── static/
│   │   ├── data.json
│   │   └── noticias_data.json
│   ├── 20260611_hoja_de_ruta_acercamiento_investigadores.html
│   ├── catastro_pure.csv
│   ├── index.html
│   ├── INSTRUMENTOSAB_ENCUESTAS.pptx
│   ├── mapa_investigacion.html
│   ├── MVP_dashboard_empleabilidad.html
│   ├── noticias_economia_dashboard.html
│   ├── oferta_posgrados.html
│   ├── presentaci_n_ejecutiva_arquitecturamedallon.html
│   └── Presentación1.pptx
├── .env.example
├── .gitignore
├── CORRECCIONES_NIVEL_INSTRUCCION.md
├── data.csv
├── empleabilidad_mvp.pbip
├── environment.yml
├── excel.py
├── generar_mapa.py
├── investigadores_uc.xlsx
├── investigadores_ucuenca.csv
├── investigadores_ucuenca.xlsx
└── matriz_contratos_ucuencav1.xlsx

```

Los archivos de datos de la capa Bronze no se versionan en el repositorio por contener datos personales (LOPD).

2. scripts/run_enemdu_pipeline.py (primeras 80 líneas)

```

#!/usr/bin/env python
"""
run_enemdu_pipeline.py
=====
Orquestador del pipeline ENEMDU (Bronze → Silver → Gold).

Ejemplos
-----
    python scripts/run_enemdu_pipeline.py --all
    python scripts/run_enemdu_pipeline.py --audit
    python scripts/run_enemdu_pipeline.py --silver --gold --years 2021 2022 2023
    python scripts/run_enemdu_pipeline.py --all --sample 50000 # prueba rápida
"""

from __future__ import annotations

import argparse
import sys
import time
from pathlib import Path

ROOT = Path(__file__).resolve().parents[1]
if str(ROOT) not in sys.path:
    sys.path.append(str(ROOT))

from src.processing import ( # noqa: E402
    ENEMDUGoldBuilder,
    ENEMDUSchemaAnalyzer,
    ENEMDUSilverBuilder,
    get_logger,
    load_silver,

```

```

)

log = get_logger("pipeline_enemdu")

def parse_args() -> argparse.Namespace:
    p = argparse.ArgumentParser(description="Pipeline medallón ENEMDU 2021-2025")
    p.add_argument("--audit", action="store_true", help="Analiza esquemas y audita Bronze")
    p.add_argument("--silver", action="store_true", help="Construye la capa Silver")
    p.add_argument("--gold", action="store_true", help="Construye la capa Gold")
    p.add_argument("--all", action="store_true", help="Ejecuta las tres etapas")
    p.add_argument("--years", nargs="+", type=int, default=None, help="Años a procesar")
    p.add_argument("--sample", type=int, default=None,
                    help="Filas por año (modo prueba, no usar en producción)")
    p.add_argument("--no-csv", action="store_true", help="No exportar CSV para Power BI")
    return p.parse_args()

def main() -> int:
    args = parse_args()
    if not any((args.audit, args.silver, args.gold, args.all)):
        args.all = True

    t0 = time.time()
    analyzer = ENEMDUSchemaAnalyzer(years=args.years)

    if args.audit or args.all or args.silver:
        log.info("— Etapa 1/3: análisis de esquemas y auditoría Bronze —")
        analyzer.analyze_all()
        print(analyzer.summary().to_string(index=False))
        if args.audit or args.all:
            print(analyzer.audit().to_string(index=False))
        analyzer.save_report()

    if args.silver or args.all:
        log.info("— Etapa 2/3: construcción de Silver —")
        builder = ENEMDSilverBuilder(analyzer=analyzer, years=args.years)
        result = builder.build(sample_rows=args.sample)
        print(result.quality.to_string(index=False))
        builder.save(result)

    if args.gold or args.all:
        log.info("— Etapa 3/3: construcción de Gold —")
        silver = load_silver(analyzer.paths)
        gold = ENEMDUGoldBuilder(silver, paths=analyzer.paths)
        res = gold.build()
        print(res.kpi_anual.to_string(index=False))
        gold.save(res, export_csv=not args.no_csv)

    log.info("Pipeline finalizado en %.1f s", time.time() - t0)

```

3. Módulos del pipeline (src/processing)

```

src\processing\__init__.py
src\processing\enemdu_gold_builder.py
src\processing\enemdu_mappings.py
src\processing\enemdu_schema_analyzer.py
src\processing\enemdu_silver_builder.py
src\processing\io_utils.py
src\processing\noticias_sentimiento.py

```

4. Notebooks del repositorio

```
notebooks\01_docentes\01_ingesta_gth_pure.ipynb
notebooks\01_docentes\02_fuzzy_matching_dspace.ipynb
notebooks\01_download_kaggle_enemdu.ipynb
notebooks\02_review_sav_labels.ipynb
```

Relevantes al pipeline ENEMDU: **notebooks/01_download_kaggle_enemdu.ipynb** (descarga y Bronze→Silver→Gold) y **notebooks/02_review_sav_labels.ipynb** (revisión de etiquetas .sav).

5. Diccionario de variables ENEMDU

Diccionarios por año disponibles: Diccionario de Datos_persona_anual_2021.xlsx, Diccionario de Datos_persona_anual_2023.xlsx, Diccionario de Datos_persona_anual_2024.xlsx, Diccionario de Datos_persona_anual_2025.xlsx, Diccionario de Datos_personas_anual_2022.xlsx

Institución	Instituto Nacional de Estadística y Censos		
Identificador	INEC_PDA_2025		
Documento Referencia	INEC_DIES_ENEMDU_2025		
Nombre	BDDenemdu_personas_2025_anual		
Descripción	La Tabla de datos de la Encuesta Nacional de Empleo, Desempleo y Subem		
Nombre del campo	Descripción del campo		
area	Area		
ciudad	Ciudad		
conglomerado	Conglomerado		
panelm	Panelm		
vivienda	Vivienda		
hogar	Hogar		
p01	Persona		
p02	Sexo		
p03	Edad		
p04	Relación de Parentesco		
p05a	Seguro Social - Alternativa 1		
p05b	Seguro Social - Alternativa 2		
p06	Estado civil		
p07	Asiste a clases		
p08	Jornada a la que asiste		
p09	Razón por la que no asiste		
p10a	Nivel de instrucción		
p10b	Año aprobado		
p11	Sabe leer y escribir		
p12a	Por sus estudios obtuvo algún título		
p12b	Qué título obtuvo		
p15	Como se considera		
p15aa	Dónde nació		

p15ab	Lugar de nacimiento		
cod_inf	Código del Informante		
p20	Trabajó la semana pasada		
p21	Actividad que realizó para ayudar en su hogar		
p22	Tiene trabajo del cual estuvo ausente		
p23	Razón por la que no trabajó		
p24	Horas de trabajo en la semana anterior		
p25	Razón por la que trabajó menos de 40 horas		
p26	Razón por la que trabajó mas de 40 horas		
p27	Desea trabajar más horas		
p28	Está disponible para trabajar horas adicionales		
p29	Cuántas horas a la semana estaría disponible para trabajar		
p30	Gestión realizada para cambiar la situación actual de trabajo		
p31	Razón por la que busca cambiar la situación actual de trabajo		
p32	Buscó trabajo el mes anterior		
p33	Semanas que busca trabajo		
p34	Razón por la que no buscó trabajo		
p35	Desea trabajar y está dispuesto a hacerlo		
p36	Condición de inactividad		
p37	Trabajó anteriormente		
p38	Motivos por los que dejó de trabajar		
p39	Número de semanas que no trabaja		
p40	Rama de actividad		
p41	Grupo de ocupación		
p42	Categoría de ocupación		
p42a	Es socio de cooperativa o asociación		
p43	El trabajo que tiene es		
p44a	Recibe alimentación		
p44b	Recibe vivienda		
p44c	Recibe transporte		
p44d	Recibe vacaciones		
p44e	Recibe ropa de trabajo		
p44f	Recibe seguro social		
p44g	Recibe seguro médico		
p44h	Recibe guardería		
p44i	Recibe cursos de capacitación		
p44j	Recibe 13vo sueldo		
p44k	Recibe 14vo sueldo		
p45	Cuántos años trabaja		
p46	Sitio de trabajo		
p47a	Tamaño del establecimiento		

6. Commits de septiembre 2026 (25)

```
6505786 catastro docentes actualizacion powerbi
6626fcd agregado powerbi posgrados
684ad70 agregado que es prototipo
b921a26 eliminado el footer
76e3ef3 mejora
e35bb29 autoria
6732489 autoria y mejora conexion de dtos
32dc399 agregado autoria
20de1ff noticias con fecha
8ff7d03 actualizamos el dashboard de noticias
389b995 feat: automatizar scraping de noticias de economia con GitHub Actions
f528b78 fix: quitar tarjeta de tamaño muestral del dashboard de empleabilidad
8cdf9b8 fix: destrabar noticias_data.json del .gitignore (*.json lo bloqueaba)
0c01bef fix: Update project name to UCuenca-SABE! across documentation and scripts
33c9fd7 feat: Implement news sentiment analysis and scraping for economic news
c5d6200 bosquejo del fuzzy matching por corroborar
ee62378 se mantiene la lógica de los pipelines, se evita redundancias , la 01 ingesta se actualiza y se hace que
queden dos bases la del merge y la que une ambas
520d591 Merge branch 'main' of github.com:MichelleLuzA/ucuenca-sabe
9dbcf43 mejoras
21b1ada Mejora de la auditoría: delete src/processing/enemdu_schema.py – confirmado: src.processing sigue
importando igual (ENEMDUSchemaAnalyzer resuelve al módulo correcto). delete notebooks/ensure_bronze.py +
notebooks/02_download_kaggle_enemdu_MEJORADO.ipynb – sin referencias vivas en ningún lado. delete ciuo_mapping en
generate_dashboard_data.py – regeneré data.json y corrí el test funcional contra el HTML (renderLanding, ambos
segmentos ENEMDU, sobrecalificación): 4/4 sin excepciones, sin undefined/NaN. shrink excel.py → helpers
fill()/borde(), 23+7 llamadas repetidas colapsadas. Verificación dura: generé el .xlsx antes y después y comparé
byte a byte cada miembro del zip – único diff es el timestamp de creación de openpyxl (esperado, no de contenido).
Estilos, bordes, datos, validaciones: idénticos
6801d90 Revise README for UCuenca-SABE! project
d88da7e se agrega nnivins en base silver
565aeba fix: publicar visualizacion/static/data.json para GitHub Pages
707e116 actualizado todo
99c0204 generacion del visualizador
```